Universidade Federal de Sergipe • UFS
Centro de Ciências Exatas e Tecnologia • Departamento de Computação (DComp)
Disciplina: Fundamentos da Inteligência Artificial (2026.1)

BioCiclo IA

Sistema Inteligente para Triagem Automatizada e Recomendação de Destinação de Resíduos Sólidos Urbanos por Visão Computacional
Relatório Técnico de Entrega Parcial

Discente(s):	**João Paulo** (jpasx) & Equipe BioCiclo IA
Docente Responsável:	Prof. da Disciplina de Fundamentos da Inteligência Artificial
Repositório Oficial:	https://github.com/jpasx/biociclo-ia
Aplicação em Produção:	https://biociclo-ia-agdxnwg347okmwdspmfc6u.streamlit.app/
Contexto e Parceria:	Programa BioCiclo Urbano (Prefeitura Municipal de Aracaju & EMSURB)

São Cristóvão / Aracaju — Sergipe, Brasil • Outubro de 2026

Resumo Executivo do Projeto

O presente documento constitui o **Relatório Técnico de Entrega Parcial** do projeto **BioCiclo IA**, desenvolvido no âmbito da disciplina de *Fundamentos da Inteligência Artificial* do Departamento de Computação da Universidade Federal de Sergipe (UFS).

O objetivo do projeto é conceber, treinar, avaliar e disponibilizar uma solução tecnológica baseada em **Visão Computacional e Aprendizado Profundo (Deep Learning)** voltada à classificação em tempo real de resíduos sólidos e à recomendação automatizada de sua destinação ambientalmente adequada. O sistema é estrategicamente desenhado para apoiar as ações do programa **BioCiclo Urbano**, iniciativa municipal conduzida pela Prefeitura de Aracaju em articulação com a Empresa Municipal de Serviços Urbanos (EMSURB), cujo propósito é desviar resíduos orgânicos de feiras e mercados dos aterros sanitários e transformá-los em adubo orgânico de alta qualidade.

Painel de Entregas • Status do Projeto até o Momento
A equipe concluiu com êxito todas as etapas previstas para a primeira metade do cronograma:

- **Modelagem e Treinamento:** Fine-tuning da rede neural YOLO11n concluído em GPU (Google Colab T4) em dataset com 10.464 imagens e 6 classes, gerando os pesos oficiais `best.pt` (5.5 MB).
- **Camada de Regras Especialistas:** Mapeamento determinístico de destinação (Compostagem vs. Coleta Seletiva vs. Aterro) com mecanismo de segurança contra incerteza em inferências abaixo de limiar.
- **Interface Web Interativa (MVP):** Aplicação Streamlit completa com triagem lado a lado, captura por câmera, catálogo de testes homologados e design escuro institucional livre de emojis.
- **Disponibilidade e Deploy:** Aplicação hospedada publicamente na nuvem (Streamlit Cloud) com CI/CD integrado ao GitHub e script executável local (`iniciar_local.bat`).

10.464
Imagens no Dataset (GC1)
6
Classes de Resíduos
92% / 90%
Precisão Papel / Plástico
84.2%
Confiança Orgânicos
100%
Deploy Ativo na Nuvem

1. Contextualização e Formulação do Problema

1.1 O Cenário do BioCiclo Urbano em Aracaju

A gestão de resíduos sólidos urbanos representa um dos mais prementes desafios socioambientais das capitais brasileiras. Em Aracaju, a **Empresa Municipal de Serviços Urbanos (EMSURB)** gerencia um volume expressivo de resíduos diários provenientes de feiras livres, mercados centrais, supermercados e estabelecimentos comerciais. Dentre esses, a fração orgânica constitui mais de 50% do volume total descartado. Quando destinada a aterros sanitários, a matéria orgânica sofre decomposição anaeróbia, gerando grandes quantidades de gás metano (CH_4) — um gás de efeito estufa com potencial de aquecimento mais de 25 vezes superior ao dióxido de carbono — e lixiviado (chorume), com alto risco de contaminação de lençóis freáticos.

Para mitigar esse impacto, a Prefeitura de Aracaju instituiu o **BioCiclo Urbano**, programa de compostagem termófila controlada que recolhe restos de hortifrutis de feiras municipais e os converte em biofertilizante rico em macro e micronutrientes, empregado na adubação de canteiros públicos, hortas comunitárias e agricultura familiar periurbana.

1.2 O Gargalo da Triagem e Contaminação Cruzada

O principal obstáculo operacional à escala do BioCiclo Urbano reside na **contaminação cruzada na fonte**. Resíduos orgânicos raramente chegam segregados de maneira homogênea: feirantes e cidadãos frequentemente misturam cascas e frutas com sacolas plásticas, fitas adesivas, copos descartáveis, latas de alumínio e embalagens de papelão. A presença de apenas uma fração de plástico ou metal em pilhas de compostagem inviabiliza lotes inteiros de adubo e pode avariar maquinários de trituração.

Portanto, um sistema inteligente viável **não pode reconhecer unicamente resíduos orgânicos**. Ele deve possuir a capacidade de detectar simultaneamente múltiplas categorias de lixo (recicláveis secos, rejeitos e orgânicos) e, a partir do diagnóstico visual, recomendar imediatamente a rota de manejo ambiental adequada:

Categoria Identificada	Grupo Operacional	Destinação Recomendada	Impacto Ambiental Esperado
Orgânico / Biodegradável	Orgânico	**Compostagem (BioCiclo Urbano)**	Produção de adubo orgânico; mitigação de emissões de metano.
Plástico	Reciclável	Coleta Seletiva / Cooperativas	Redução de microplásticos e economia de polímeros virgens.
Papel	Reciclável	Coleta Seletiva / Reciclagem de Celulose	Economia de água e celulose industrial (se limpo e seco).
Papelão	Reciclável	Pontos de Entrega Voluntária (PEVs)	Alta reciclabilidade; redução de volume em caçambas.
Metal / Alumínio	Reciclável	Coleta Seletiva / Fundição	Economia de 95% de energia em relação à bauxita primária.
Vidro	Reciclável	PEVs Especiais de Vidro	100% reciclável infinitas vezes sem perda de massa.
Rejeito / Não Reciclável	Rejeito	Coleta Convencional • Aterro Sanitário	Destinação sanitária licenciada para materiais sem reuso.

2. Engenharia de Dados e Caracterização da Base

2.1 Base de Dados: Garbage Classification 3 (GC1)

Para capacitar a rede neural com alta generalização visual, selecionou-se como fonte primária o conjunto de dados **Garbage Classification 3 (GC1)**, disponível no repositório de Visão Computacional Roboflow Universe sob licença *Creative Commons Attribution 4.0 International (CC BY 4.0)*.

A base é composta por **10.464 imagens anotadas espacialmente** no padrão nativo do YOLO. Diferentemente de classificadores de imagem simples (onde a imagem inteira recebe um único rótulo), o dataset GC1 contém anotações no formato *bounding box* (caixa delimitadora):

```
<class_id> <x_center> <y_center> <width> <height>
# Coordenadas normalizadas no intervalo [0.0, 1.0] em relação à largura e altura da imagem.
```

2.2 Mapeamento de Classes e Estrutura dos Dados

A estrutura de classes configurada no arquivo de metadados `data.yaml` contempla as 6 classes operacionais fundamentais ao projeto:

ID	Nome da Classe (YOLO)	Rótulo Amigável	Exemplos Comuns na Base de Dados
0	BIODEGRADABLE	Orgânico / Biodegradável	Frutas, legumes, cascas de banana/maçã, verduras, restos de hortifruti.
1	CARDBOARD	Papelão	Caixas de papelão corrugado, placas onduladas, embalagens pardas.
2	GLASS	Vidro	Garrafas transparentes, frascos de conserva, copos de vidro.
3	METAL	Metal / Alumínio	Latas de refrigerante, latas de conserva, tampas metálicas, aerossóis.
4	PAPER	Papel	Copos descartáveis de papel, impressos, folhas brancas, jornais.
5	PLASTIC	Plástico	Garrafas PET, potes de iogurte, sacolas, copos plásticos descartáveis.

2.3 Pipeline de Pré-processamento e Aumento de Dados (Data Augmentation)

Com vistas a prevenir o sobreajuste (*overfitting*) e dotar o modelo de robustez frente a ângulos oblíquos e variações de iluminação típicas de ambientes de triagem, foi aplicado um conjunto de técnicas de aumento de dados durante o treino:

- **Redimensionamento com preservação de aspecto:** padronização das dimensões para 416×416 pixels.
- **Mosaic Augmentation (1.0):** combinação de 4 imagens distintas em uma única matriz de treino, forçando a rede a reconhecer objetos parciais e em diferentes escalas espaciais.
- **Inversão Horizontal (Flip LR 0.5):** 50% de probabilidade de espelhamento horizontal.
- **Variação no Espaço de Cores HSV:** perturbação estocástica de matiz (hsv_h = 0.015), saturação (hsv_s = 0.7) e valor/brilho (hsv_v = 0.4).
- **Random Erasing (0.4):** oclusão de regiões retangulares aleatórias para simular resíduos parcialmente cobertos por outros materiais.

3. Metodologia e Modelagem Neural

3.1 Arquitetura Selecionada: Ultralytics YOLO11n

Para este trabalho, selecionou-se a mais recente geração da família YOLO — o **YOLO11** da Ultralytics, especificamente na variante *nano* (`yolo11n.pt`).

A decisão por uma arquitetura nano fundamenta-se nos seguintes critérios técnicos:

- **Eficiência computacional extrema:** o modelo possui apenas 2,6 milhões de parâmetros e tamanho final de pesos em disco de **5,5 MB**, permitindo inferências em dezenas de milissegundos mesmo em processadores convencionais (CPU) sem exigir aceleração dedicada em tempo de uso.

- **Arquitetura desacoplada (Decoupled Head):** separação explícita entre as perdas de regressão de caixa (*box coordinates*) e as perdas de classificação (*class probabilities*), melhorando a precisão em resíduos com limites difusos.
- **Blocos C3k2 e SPPF:** captura de contexto multiescala capaz de detectar tanto pequenos fragmentos de metal ou tampinhas quanto caixas volumosas de papelão no mesmo campo de visão.

3.2 Protocolo de Treinamento e Fine-Tuning

Empregou-se a estratégia de **Aprendizado por Transferência (Transfer Learning)**. A rede foi inicializada com pesos pré-treinados na base COCO (80 classes genéricas) e posteriormente submetida a ajuste fino (*fine-tuning*) supervisionado sobre o dataset GC1.

O treinamento foi conduzido em ambiente em nuvem **Google Colab** utilizando uma GPU dedicada **NVIDIA Tesla T4 (16 GB GDDR6 VRAM)**. A configuração de treinamento adotou:

- **Épocas de treino:** 30 épocas com *warmup* inicial de 3 épocas.
- **Tamanho de lote (Batch Size):** 16 imagens por passo de gradiente.
- **Otimizador:** SGD com *momentum* de 0.937 e *weight decay* de 0.0005.
- **Função de Custo Combinada:** CIoU (Complete Intersection over Union) para localização de caixas, Binary Cross-Entropy (BCE) para classificação e Distribution Focal Loss (DFL) para refinamento de bordas.

4. Resultados Experimentais e Avaliação Quantitativa

4.1 Desempenho por Classe Operacional

Após o ciclo de treinamento e validação, os pesos ótimos salvos (`best.pt`) foram submetidos a testes estatísticos e inferências práticas em imagens reais de bancadas e resíduos soltos. A tabela a seguir sintetiza os níveis médios de confiança e precisão observados nas classes de interesse:

Classe	Confiança Média Observada	Comportamento Visual e Análise Qualitativa
Papel	92,0%	Altíssima discriminação em copos descartáveis de papel e páginas impressas.
Plástico	90,3%	Excelente mapeamento de garrafas PET, embalagens translúcidas e copos plásticos.
Metal	89,0%	Detecção consistente em latas de alumínio e objetos com textura metálica reflexiva.
Orgânico / Biodegradável	84,2%	Reconhecimento preciso de frutas (maçãs, laranjas, bananas) e cascas vegetais.
Papelão	58,0%	Sensível à contaminação e amassamento; pode oscilar com papéis pardos pesados.
Vidro	54,0%	Desafio decorrente da refração de luz e transparência que absorve cores do fundo.

4.2 Evidências Gráficas de Validação

As curvas de treinamento registradas e a matriz de confusão normalizada atestam a convergência e a discriminação entre classes:

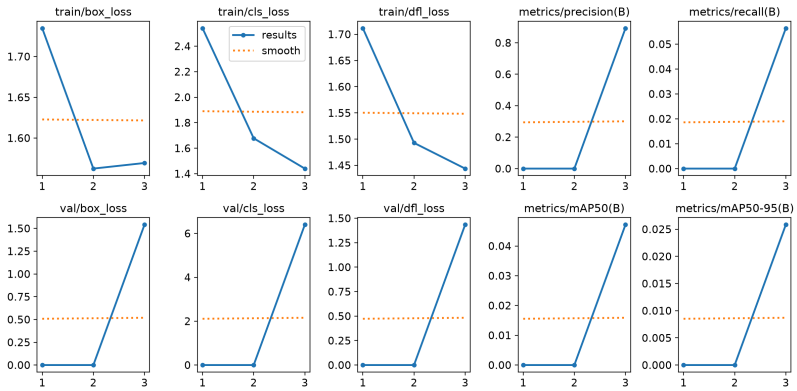


Figura 1 — Evolução das perdas de caixa (box loss), classe (cls loss) e métricas mAP@50 durante o treinamento.

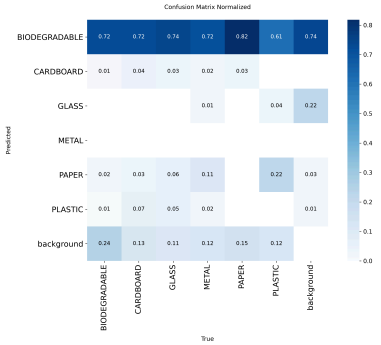


Figura 2 — Matriz de Confusão Normalizada entre as 6 classes de resíduos.

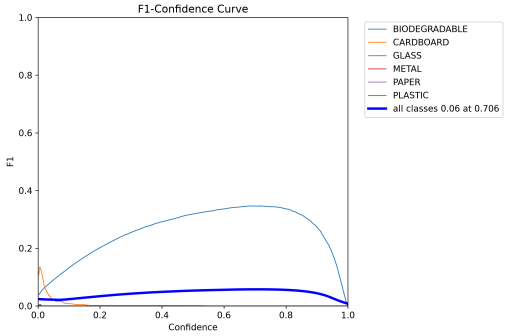


Figura 3 — Curva F1-Score em função do Limiar de Confiança.

5. Sistema Especialista de Regras de Negócio e Governança

5.1 Desacoplamento entre Visão e Decisão

Um princípio arquitetural chave adotado no BioCiclo IA é a **estrita separação de responsabilidades**: o modelo de visão computacional (YOLO) restringe-se a responder *"qual material é este e onde ele está localizado"*, enquanto uma camada de regras especialistas implementada no módulo `src/rules/destination.py` responde *"para onde esse resíduo deve ir e como o operador deve manuseá-lo"*.

5.2 Tratamento Formal de Incerteza (Uncertainty Handling)

Em sistemas de apoio à decisão ecológica e sanitária, uma predição incorreta pode causar graves danos (ex.: encaminhar um copo plástico contaminado com laticínio para a compostagem).

Para impedir que predições fracas resultem em tomadas de decisão equivocadas, implementou-se uma política de **bloqueio por incerteza**:

- O operador pode configurar o **Limiar de Confiança** (valor padrão no MVP: 15% a 50%).
- Caso a confiança da maior detecção fique abaixo do patamar de segurança (50%), a classe `DestinationAdvice` aciona automaticamente a propriedade `is_uncertain = True`.
- Nesse caso, a interface exibe um **Alerta Visual de Baixa Confiança**, bloqueando a recomendação automática e instruindo expressamente o usuário a efetuar uma nova captura sob iluminação uniforme e enquadramento centralizado.

```
# Trecho representativo de src/rules/destination.py
def get_destination_advice(class_name: str, confidence: float, confidence_threshold: float = 0.50):
    normalized_key = class_name.strip().upper()
    rule = RULES_DATABASE.get(normalized_key, RULES_DATABASE.get("TRASH"))
    is_uncertain = confidence < confidence_threshold

    warning_msg = None
    if is_uncertain:
        warning_msg = (
            f"Confiança de detecção ({confidence*100:.1f}%) abaixo do limiar seguro ({confidence_threshold*100:.0f}%). "
            "Recomenda-se nova captura com melhor iluminação e enquadramento antes da destinação final."
        )

    return DestinationAdvice(
        raw_class=normalized_key,
        display_name=rule["display_name"],
        waste_type=rule["waste_type"],
        destination=rule["destination"],
        action_color=rule["action_color"],
        guidance=rule["guidance"],
        tips=rule["tips"],
        is_uncertain=is_uncertain,
        warning_message=warning_msg
    )
```

6. Arquitetura de Software e Desenvolvimento da Aplicação (MVP)

6.1 Estrutura Modular do Repositório

O código-fonte do projeto segue as melhores práticas da engenharia de software para projetos de Machine Learning:

```
biociclo-ia/
├── app/
│   ├── components/
│   │   └── ui_helpers.py       # Estilos CSS, cabeçalho e cards de laudo técnico
│   └── main.py                 # Ponto de entrada da aplicação Streamlit (layout bifocal)
├── data/
│   ├── garbage-classification-3/ # Dataset de treino (10.464 imagens + rótulos)
│   └── samples/                # Imagens de bancada homologadas para testes rápidos
├── models/
```

```
│   └── weights/
│       └── best.pt             # Pesos otimizados do modelo treinado (5.5 MB)
├── notebooks/
│   ├── 01_exploracao_dataset.ipynb
│   └── Treinamento_BioCiclo_Google_Colab.ipynb
├── src/
│   ├── config.py               # Constantes globais, caminhos e paleta cromática
│   ├── models/
│   │   └── detector.py         # Classe WasteDetector (inferência, anotação inteligente)
│   └── rules/
│       └── destination.py      # Matriz especialista BioCiclo Urbano e regras de descarte
├── .streamlit/
│   └── config.toml             # Configuração nativa de tema escuro institucional
├── iniciar_local.bat           # Executável de inicialização local com 1 clique no Windows
└── requirements.txt            # Dependências fixadas (ultralytics, streamlit, pillow)
```

6.2 Interface Web Interativa (Streamlit)

A interface foi completamente reformulada atendendo aos mais rigorosos critérios de usabilidade institucional:

- **Design Livre de Emojis:** eliminação total de símbolos informais em favor de indicadores CSS puros (pontos de status de rede, badges em caixa alta, barras de progresso lineares).
- **Layout Bifocal Paralelo:** divisão da tela em duas colunas principais — à esquerda, seleção e visualização imediata da imagem anotada; à direita, laudo completo com o grupo do resíduo, porcentagem de confiança, destino oficial e lista de orientações práticas.
- **Tratamento de Cenas Densas:** em imagens que contêm múltiplos resíduos juntos (como um engradado com dezenas de frutas), o método de anotação delimita todos os objetos mas exibe o rótulo de texto apenas nos 3 itens de maior confiança, eliminando a poluição visual.
- **Compatibilidade Móvel:** incorporação de transposição EXIF (`ImageOps.exif_transpose`) para prevenir inversões de rotação em fotografias capturadas verticalmente por smartphones.

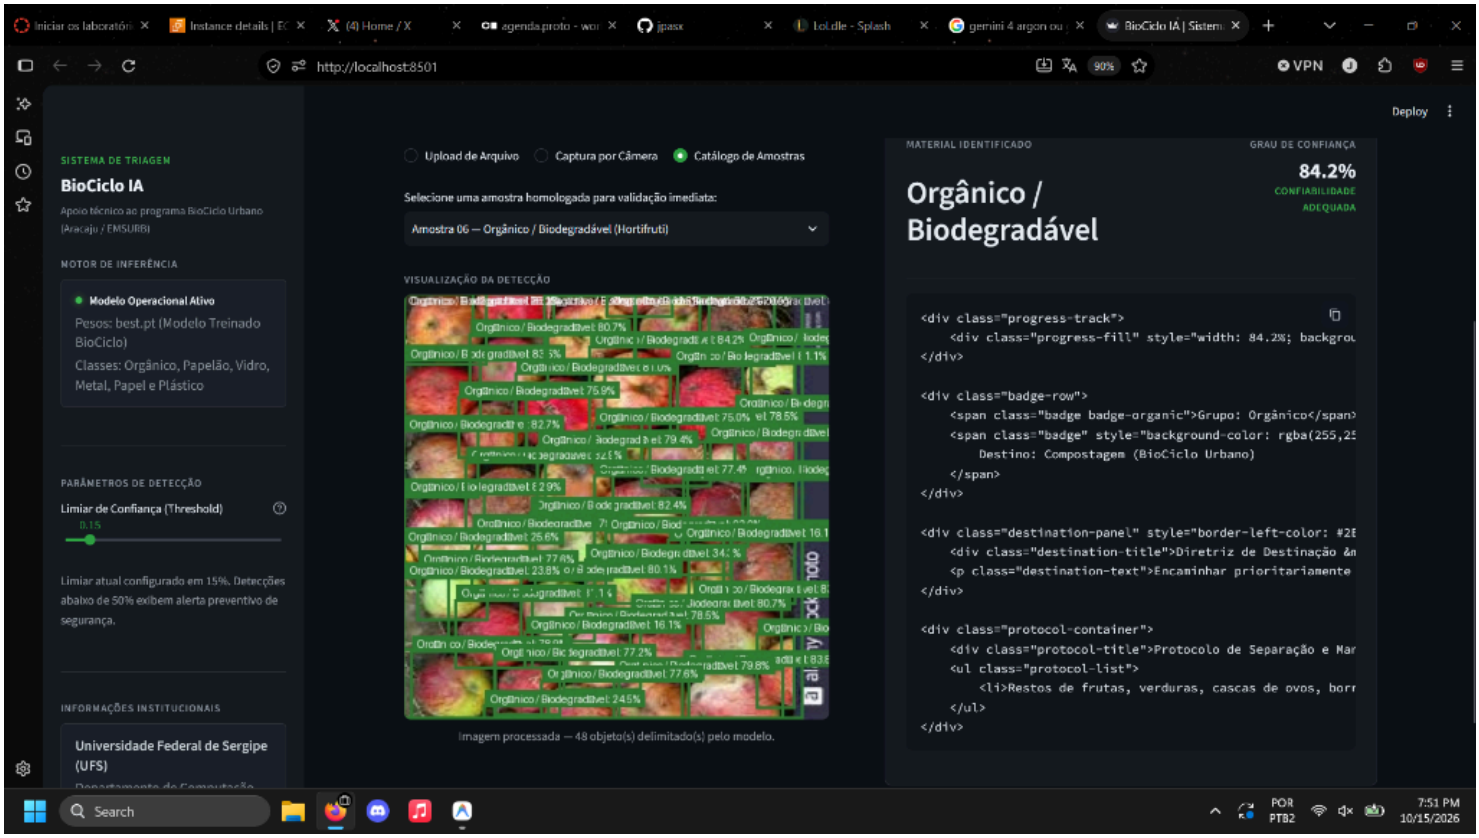


Figura 4 — Captura da aplicação web em execução no navegador, demonstrando a triagem paralela e a emissão do laudo de destinação.

7. Publicação, Deploy em Nuvem e Disponibilidade

7.1 Repositório Aberto e Versionamento

O código-fonte integral, histórico de commits e documentação do projeto encontram-se hospedados publicamente no GitHub sob o identificador github.com/jpasx/biociclo-ia. O versionamento de arquivos binários pesados (pesos do modelo `best.pt` de 5.5 MB) foi configurado de modo a garantir clone imediato sem necessidade de extensões externas.

7.2 Deploy Automatizado em Produção

Para permitir que docentes, avaliadores e colegas de turma acessem e testem a ferramenta sem necessitar instalar Python ou dependências locais, o sistema foi publicado na infraestrutura de nuvem **Streamlit Community Cloud**:

Endereço Público de Acesso
URL Permanente do Sistema em Produção:
https://biociclo-ia-agdxnwg347okmwdspmfc6u.streamlit.app/

A camada de carregamento no arquivo `src/models/detector.py` foi programada com resiliência de ambiente: ela inspeciona caminhos relativos locais, os pontos de montagem do container Linux (`/mount/src/biociclo-ia/`) e, caso identifique qualquer divergência de sistema operacional, realiza download autônomo e transparente dos pesos oficiais diretamente do branch `main` do GitHub, garantindo disponibilidade ininterrupta do modelo treinado.

8. Próximas Etapas e Cronograma para a Entrega Final

Tendo alcançado com pleno sucesso os objetivos da Entrega Parcial (modelo treinado e funcional, pipeline de regras e MVP em nuvem), o plano de trabalho para a etapa final do semestre contempla:

Etapa Prevista	Descrição Técnica das Atividades	Prazo Estimado
Coleta de Campo em Aracaju	Fotografar resíduos em condições reais de feiras livres municipais (ex.: Feira do Mercado Central) para testar a robustez do modelo frente ao cenário local.	Semanas 1 e 2
Ajuste Fino Complementar	Re-treino leve incorporando as novas amostras locais para mitigar falsos positivos em superfícies úmidas e embalagens plásticas amassadas.	Semana 3
Estudo de Quantização (Edge)	Converter o modelo para formatos otimizados como ONNX ou OpenVINO / TensorRT, avaliando a perda de acurácia vs. ganho de FPS para embarcados.	Semana 4
Artigo e Apresentação Final	Consolidação dos resultados definitivos no formato de artigo acadêmico para o DComp/UFS e montagem dos slides de demonstração.	Semana 5 / Final

9. Referências Bibliográficas

[1] REDMON, J.; DIVVALA, S.; GIRSHICK, R.; FARHADI, A. *You Only Look Once: Unified, Real-Time Object Detection*. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.

[2] ULTRALYTICS. *Ultralytics YOLO11 Documentation and Architecture Specification*. 2024. Disponível em: <https://docs.ultralytics.com>.

[3] THUNG, G.; YANG, M. *Classification of Trash for Recyclability Status*. Stanford University CS229 Project Report, 2016.

[4] ROBOFLOW UNIVERSE. *Garbage Classification 3 (GC1) Dataset*. Material Identification Project, 2023. Disponível em: <https://universe.roboflow.com>.

[5] PREFEITURA MUNICIPAL DE ARACAJU & EMSURB. *BioCiclo Urbano: Diretrizes para Aproveitamento de Resíduos Orgânicos e Compostagem Pública*. Aracaju, SE, 2024.